Plano de execução — Qualidade de RX de tórax e classificadores de pneumonia

Oct 17, 2026 · @Aline Lima

Como usar este documento

O planejamento (fases 0 a 4 do roteiro) é tratado como concluído; a execução começa pela infraestrutura e pela auditoria, e nenhuma fase avança sem o portão (gate) da anterior aprovado.

- **Fases:** F0 a F13, na ordem do seu roteiro. Cada fase tem objetivo, passos marcáveis, entregáveis, portão de saída e decisões a registrar.
- **Portões:** G3 (bases aprovadas), G4 (protocolo congelado), G5 (baseline estável), G6 (teste destrancado), G11 (análises fechadas). Um portão só é aprovado com evidência anexada ao diário.
- **IDs:** decisões `D-001` …, desvios `DV-001` …, entradas de diário `J-AAAAMMDD`. Toda decisão cita a seção do protocolo que ela altera ou confirma.
- **Regra de ouro:** antes de G4, mudar o protocolo é decisão (D). Depois de G4, qualquer mudança é desvio (DV), com data, motivo e impacto (protocolo §12).
- **Onde guardar:** no repositório, `docs/decisoes/`, `docs/desvios/`, `docs/diario/`; listas de IDs com hash em `data/splits/`; tabelas de predição em `results/predicoes/`. Este documento é o índice; os registros detalhados vivem no repositório.

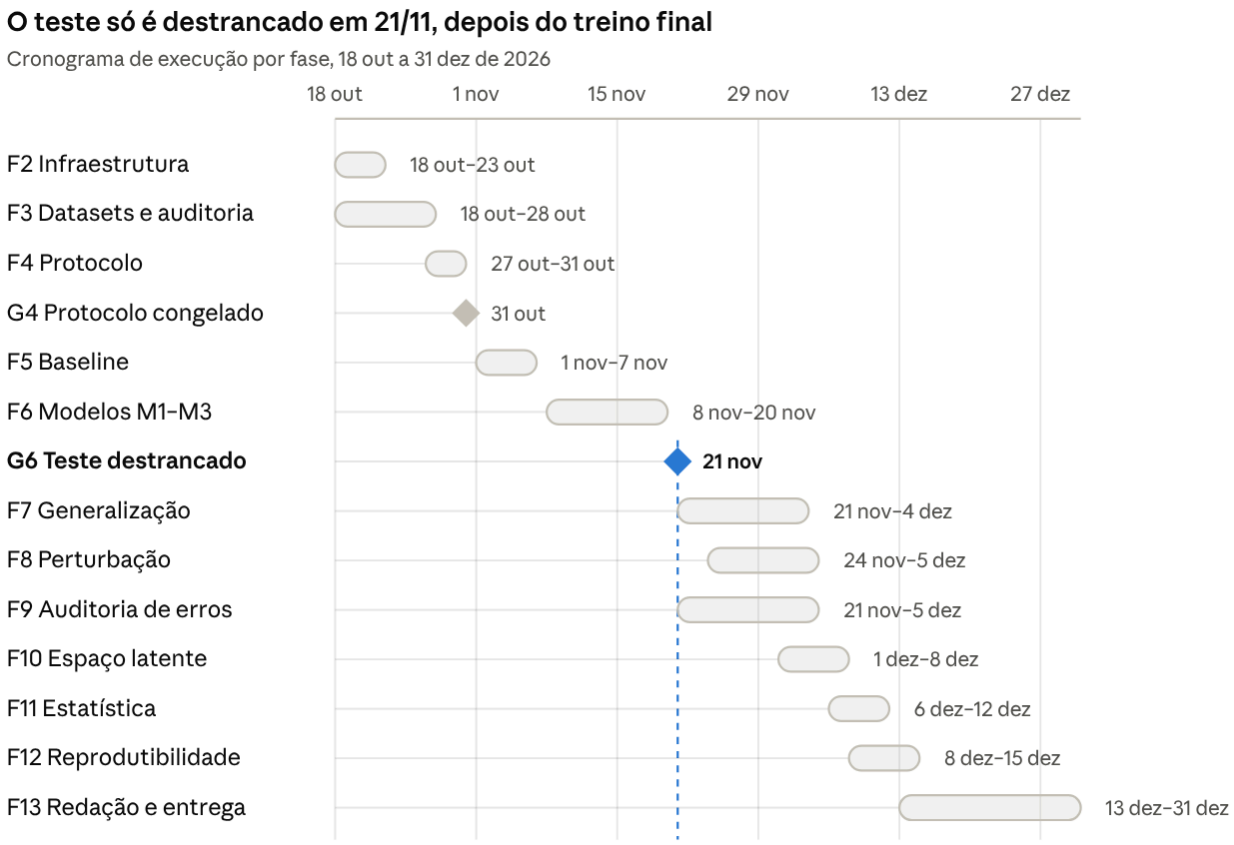
Visão geral e cronograma

F0 e F1 estão concluídas; F2 a F4 fecham até 31/10; o treino ocorre de 1 a 20/11; o teste é destrancado em 21/11; as análises terminam em 12/12 e a redação ocupa o resto de dezembro.

A numeração segue o seu roteiro. A fase 2 não aparecia na lista; usei o número para infraestrutura, que hoje é pendência solta no protocolo (GPU, disco, Windows). Se a F2 já tinha outro conteúdo, renumere aqui.

Fase	Conteúdo	Protocolo	Portão de saída	Status
F0 Delimitação	Pergunta provisória, objetivo, limites	§2	—	Concluída

Fase	Conteúdo	Protocolo	Portão de saída	Status
F1 Fundamentação	Física, aquisição, qualidade, interpretação	§2.1, §4.3	—	Concluída
F2 Infraestrutura	Repositório, ambiente, GPU, armazenamento, cache	§7.4, §11	G2: teste de fumaça	Não iniciada
F3 Datasets e auditoria	Portas 1 e 2, rótulos, ROI, features	§3, §4, §6	G3: bases aprovadas	Em andamento
F4 Protocolo	Pendências, acréscimos, splits, congelamento	§5, §9, §12	G4: protocolo congelado	Em andamento
F5 Baseline	Pipeline DenseNet121, piloto M1, sanidade	§7.1, §7.2	G5: baseline estável	Não iniciada
F6 Modelos	M1–M3 × 5 sementes, limiar, temperatura	§7.3	G6: teste destrancado	Não iniciada
F7 Generalização	E0, T1, T2, eixo C	§8.1, §8.2, §8.5	—	Não iniciada
F8 Perturbação controlada	Eixo B	§8.4	—	Não iniciada
F9 Auditoria de erros	Eixo A, revisão qualitativa, T3	§8.2, §8.3	—	Não iniciada
F10 Espaço latente e explicabilidade	Sondas lineares, saliência	novo (v1.1)	—	Não iniciada
F11 Condição estatística	Multiplicidade, IC, cenários S1–S5	§9, §10	G11: análises fechadas	Não iniciada
F12 Reprodutibilidade	Reexecução, checklists, model card	§7.4, §9	—	Não iniciada
F13 Redação e entrega	Texto, figuras, limitações	§10, §11	Entrega	Não iniciada



cronograma de execução · 12 fases, 2 portões

G4 (31/10) separa o planejamento da execução e G6 (21/11) separa o treino das análises; F7 a F10 correm em paralelo sobre a mesma tabela de predições. A data final de entrega ainda precisa ser confirmada.

F0 a F2 — Delimitação, fundamentação e infraestrutura

F0 Delimitação (concluída)

A pergunta provisória foi registrada e depois refinada na pergunta principal do protocolo (§2.2). O registro histórico fica assim, para mostrar a evolução:

- **Pergunta provisória (F0):** como características de qualidade e apresentação das radiografias de tórax se relacionam com os erros, a calibração e a generalização de modelos de classificação entre diferentes bases de dados?
- **Por quê:** comporta luminosidade, contraste, qualidade da imagem, FP/FN e avaliação externa, e permite ampliar depois para outros achados.
- **Refinamento (F4):** restringiu para pneumonia em adultos, um modelo fixo, três fontes independentes e linguagem de associação, não causal. Registrado em D-001 e D-017.

F1 Fundamentação (concluída, falta conferir a síntese)

A fundamentação está concluída; o que falta é provar que cada tema estudado virou uma decisão experimental.

- [ ] Conferir que a síntese liga cada tema a uma seção: física e aquisição → §4.3b; processamento do fabricante → §4.3a; qualidade de imagem → §6; interpretação e rótulos → §4.3c
- [ ] Ler na íntegra as 8 referências marcadas com † (2, 3, 6, 7, 8, 9, 14, 15) e atualizar a marcação
- [ ] Registrar no diário a data de conclusão e o arquivo da síntese

F2 Infraestrutura (18/10 a 23/10)

Objetivo: um ambiente reprodutível que rode o pipeline completo em 100 imagens antes de qualquer dado real ser processado em escala.

1. [ ] Criar o repositório com a estrutura `data/` (fora do git), `data/splits/`, `src/`, `configs/`, `results/`, `docs/decisoes/`, `docs/desvios/`, `docs/diario/`
2. [ ] Fixar o ambiente (versão de Python, PyTorch, CUDA) em arquivo de lock e registrar o hardware
3. [ ] Confirmar a GPU (pendência 7) e medir o tempo de uma época de DenseNet121 a 320 px com 1.000 imagens
4. [ ] Em Windows, decidir entre WSL2 e nativo; testar `num_workers` do DataLoader, que costuma travar em Windows
5. [ ] Configurar o rastreamento de experimentos: um YAML de configuração por execução, salvo junto da tabela de predições
6. [ ] Definir o esquema da tabela de predições (§7.4) como arquivo de schema validado em código
7. [ ] Teste de fumaça: 100 imagens fictícias passam por conversão, ROI, features, treino de 1 época e escrita da tabela

Portão G2: o teste de fumaça roda do zero com um comando, e o tempo por época está registrado.

Decisões a registrar: ambiente e sistema operacional; ferramenta de rastreamento; orçamento de computação estimado.

F3 — Datasets e auditoria (18/10 a 28/10)

A F3 decide se cada base entra e com que ressalvas; a primeira ação, hoje, é pedir o acesso ao PadChest, porque é o item de prazo mais incerto.

Passos

- [ ] 3.1 Solicitar o acesso ao PadChest (pendência 3) e registrar a data do pedido
- [ ] 3.2 Porta 1 nas três bases: as oito verificações de §4.2, uma ficha por base, até um dia cada
- [ ] 3.3 Porta 2, proveniência do pixel (§4.3a): ler os elementos DICOM listados em uma amostra estratificada por fabricante e projeção; registrar o denominador
- [ ] 3.4 Porta 2, parâmetros físicos (§4.3b): presença, unidades, plausibilidade e distribuição de kVp, corrente, tempo e índices de exposição no Plus (pendência 1)
- [ ] 3.5 RSNA: confirmar se os DICOM foram gerados a partir dos PNG de 8 bits do NIH; se sim, registrar que não há parâmetros físicos nem janela original e que as features do RSNA descrevem a imagem já convertida
- [ ] 3.6 RSNA: construir o mapeamento para o NIH (pendência 9). O `patientId` do RSNA identifica a imagem, não o paciente; o ID de paciente vem da tabela de metadados do NIH (só o CSV, não as imagens)
- [ ] 3.7 PadChest: verificar se o CSV traz campos DICOM (fabricante, centro e largura de janela, corrente, exposição). Se trouxer, usar a janela na conversão para 8 bits e incluir o PadChest no eixo A físico
- [ ] 3.8 Plus: medir o tamanho do pacote DICOM no Redivis e definir o recorte de pacientes (pendência 2)
- [ ] 3.9 Rótulos (§4.3c): contar positivos, incertos, negativos e não mencionados por base após os filtros de frontal e uma imagem por estudo; propor a política do Plus (D-018)
- [ ] 3.10 Sobreposição e duplicatas (§4.3d): hash perceptual dentro de cada base; confirmar ausência de pacientes entre origens
- [ ] 3.11 ROI (pendência 4): escolher o modelo de segmentação e documentar com que dados ele foi treinado. Evitar modelos treinados em subconjuntos do NIH ou do CheXpert; inspecionar 100 imagens por base
- [ ] 3.12 Features (§6): implementar as oito features na ROI, na resolução original; comparar duas conversões no PadChest
- [ ] 3.13 T1 e T2 exploratórios em treino e validação, nunca no teste (acréscimo A3): mostram cedo se há atalho de origem ou de qualidade

Entregáveis: ficha da Porta 1 e da Porta 2 por base; fluxograma de exclusões com contagens; tabela de positivos por partição; relatório de inspeção da ROI; distribuições das features por base.

Portão G3, por base: pelo menos 750 positivos no teste (ou 500 com 2 faixas); ID de paciente utilizável; ROI aceitável em pelo menos 95 de 100 imagens; termos de uso compatíveis. Sem parâmetros físicos no Plus, o eixo A físico é rebaixado para features de imagem.

Decisões a registrar: entrada ou saída de cada base; política de rótulo (D-018); modelo de ROI; conversão de cada fonte; tamanho dos recortes do Plus e do PadChest.

F4 — Fechamento e congelamento do protocolo (27/10 a 31/10)

A F4 transforma o rascunho v1.0 em v1.1 congelada: sem nenhum valor "a confirmar", com os acréscimos da seção de acréscimos incorporados e com o conjunto de teste trancado por hash.

Passos

- [ ] 4.1 Fechar as pendências 1, 2, 4, 5, 6 e 9; as pendências 3 (PadChest) e 7 (GPU) podem ficar abertas se a contingência estiver escrita
- [ ] 4.2 Política de rótulo do Plus. A prevalência de 2,7% do protocolo equivale a 6.042 / 223.462, ou seja, incertos fora dos positivos e "não mencionado" como negativo. Se os incertos forem excluídos, a prevalência sobe para cerca de 2,95%. Escrever a regra e a sensibilidade
- [ ] 4.3 Preencher os itens da receita sem valor: razão de subamostragem de negativos no treino; critério de "primeira frontal" (por data ou por índice); resolução em que as degradações do eixo B são aplicadas (original, antes do redimensionamento, ou 320 px)
- [ ] 4.4 Confirmar as margens de relevância (pendência 6)
- [ ] 4.5 Listar explicitamente a família de testes primários corrigida por Holm. H4 não é um teste; é uma regra de leitura
- [ ] 4.6 Incorporar ao texto a F9 qualitativa e a F10 como análises exploratórias pré-especificadas (acréscimos A1 e A2)
- [ ] 4.7 Atualizar o cronograma da §12 com as datas deste plano
- [ ] 4.8 Gerar as listas de IDs (semente 2026), calcular SHA-256 de cada lista e mover o teste para uma pasta sem acesso no código de treino
- [ ] 4.9 Pré-registrar: tag no git com o hash do PDF v1.1 e, se possível, registro no OSF (acréscimo A4)

Entregáveis: protocolo v1.1 em PDF; tabela de hashes das listas; registro de congelamento no diário.

Portão G4: protocolo v1.1 com hash registrado; nenhuma linha de código de treino lê arquivos de teste (verificado por busca no repositório).

Decisões a registrar: D-018 a D-023 (propostas abaixo); valores finais da receita; margens.

F5 — Baseline DenseNet121 + ImageNet (01/11 a 07/11)

A F5 entrega um pipeline de treino do M1 que roda duas vezes com a mesma semente e dá o mesmo resultado na validação, dentro de uma tolerância registrada; nada aqui toca o teste.

Passos

- [ ] 5.1 Cache das imagens convertidas a 320 px em 8 bits, com hash por arquivo
- [ ] 5.2 Carregador: canal único replicado em 3, normalização do ImageNet, só aumento geométrico (escala 0,9 a 1,0; rotação até 5°)
- [ ] 5.3 Correção de prior pela subamostragem de negativos, verificada na validação com prevalência natural:

$$\mathrm{logit}_{\text{corrigido}} = \mathrm{logit} + \ln\frac{\pi_{\text{nat}}}{1-\pi_{\text{nat}}} - \ln\frac{\pi_{\text{treino}}}{1-\pi_{\text{treino}}}$$

- [ ] 5.4 Piloto: M1, semente 0, as duas taxas de aprendizado; registrar curvas, época de parada e tempo por época
- [ ] 5.5 Sanidade: nenhum paciente em duas partições; treino com rótulos embaralhados deve dar AUROC perto de 0,5 na validação; sobreajuste proposital de um lote pequeno deve chegar a perda perto de zero
- [ ] 5.6 Repetir o piloto com a mesma semente e medir a diferença de AUROC (determinismo)
- [ ] 5.7 Gravar a primeira tabela de predições da validação e validá-la contra o schema da F2
- [ ] 5.8 Recalcular o orçamento: 3 modelos × 2 taxas na busca + 3 × 5 sementes finais = 21 treinos; se não couber até 20/11, aplicar a contingência da §11 (224 px ou 3 sementes) e registrar como decisão

Portão G5: M1 estável na validação; diferença entre execuções idênticas abaixo da tolerância; orçamento cabe no cronograma.

Decisões a registrar: tolerância de determinismo; tempo por treino; contingência de recursos, se usada.

F6 — Modelos M1 a M3 e destrancamento do teste (08/11 a 21/11)

A F6 termina com 15 modelos finais (3 × 5 sementes), limiar e temperatura salvos, código de análise testado na validação e congelado; só então o teste é destrancado, em 21/11.

Passos

- [ ] 6.1 Busca de taxa de aprendizado (1e-4 e 3e-4) para M1, M2 e M3 na validação da fonte, semente 0, mesma grade para todos
- [ ] 6.2 Treinar M1 (Plus), M2 (RSNA) e M3 (Plus + RSNA, amostragem balanceada por fonte), sementes 0 a 4
- [ ] 6.3 Fixar o limiar por sensibilidade de 0,90 na validação da fonte; para o M3, na validação conjunta
- [ ] 6.4 Ajustar a temperatura na validação da fonte; guardar ECE bruto e após temperatura
- [ ] 6.5 Ensaio geral (acréscimo A5): rodar E0, eixos A, B e C e T1 a T3 sobre as partições de validação, para depurar o código
- [ ] 6.6 Congelar o código de análise com uma tag no git
- [ ] 6.7 Destrancar o teste: registrar data, hora, hashes das listas e a tag do código no diário
- [ ] 6.8 Gerar as tabelas de predição de teste (interno e externos) para os 15 modelos, de uma só vez

Contingência: se o PadChest não chegar até 21/11, M1 e M2 seguem com o cruzamento Plus ↔ RSNA e o M3 fica sem externo (§7.3); registrar como DV se ocorrer depois de G4.

Portão G6: 15 modelos treinados; métricas de validação registradas; tag do código de análise criada antes de qualquer leitura do teste.

Decisões a registrar: taxa escolhida por modelo; limiares; temperaturas; data e hora do destrancamento.

F7 — Generalização (21/11 a 04/12)

A F7 mede o gap entre interno e externo para cada par e quanto dele acompanha a padronização clínica e de qualidade; depois de G6, as fases F7 a F10 leem a mesma tabela de predições e podem correr em paralelo.

Passos

- [ ] 7.1 E0: AUROC, AUPRC (com prevalência ao lado), FNR, FPR, ECE, intercepto e inclinação para cada par modelo × base; gap bruto por métrica
- [ ] 7.2 T1 confirmatório: qualidade + posição + idade + sexo prevendo pneumonia, contra baseline só de posição; versão interna e cruzada
- [ ] 7.3 T2 confirmatório: classificador de fonte (3 classes) só com features comparáveis, também dentro de positivos e de negativos
- [ ] 7.4 Eixo C, S1: pesos de importância por posição, idade e sexo; registrar tamanho efetivo, diferença média padronizada (meta < 0,1) e pesos extremos

- [ ] 7.5 Eixo C, S2: S1 + features comparáveis; calcular D_bruto, D_S1, D_S2 e as parcelas, com as regras da §8.5 (absolutos antes das razões; sem fração se D_bruto ≈ 0; sem truncar)
- [ ] 7.6 Bootstrap por paciente com reestimação dos pesos em cada reamostragem
- [ ] 7.7 Evidências complementares: suporte comum, harmonização por quantis, controles de rótulo ("Lung Opacity", baixa discordância CheXpert × CheXbert, subconjunto médico do PadChest), ajuste de prior

Entregáveis: tabela de desempenho interno e externo com IC; tabelas de T1 e T2; decomposição do gap.

Decisões a registrar: truncamento dos pesos usado; pares em que a fração não foi calculada e por quê.

F8 — Perturbação controlada (24/11 a 05/12)

A F8 aplica as seis degradações só ao teste, com severidade ancorada nos percentis da própria base, e mede a resposta de desempenho e calibração.

Passos

- [ ] 8.1 Para cada degradação (gama, contraste, brilho, desfoque, ruído, redução de resolução), calibrar o parâmetro que leva a feature aos percentis 25, 10 e 5 e espelhados 75, 90 e 95, mais um nível além da faixa
- [ ] 8.2 Verificar que a feature medida após a degradação cai de fato no percentil-alvo; registrar o erro de ancoragem
- [ ] 8.3 Avaliar os 15 modelos em cada nível; medir ΔAUROC, ΔFNR, ΔFPR e ΔECE
- [ ] 8.4 Teste de Mann-Kendall por curva; comparar o tamanho de efeito com as margens
- [ ] 8.5 Conferir o controle negativo (p25/p75): efeito abaixo da margem

Entregáveis: curvas dose-resposta por degradação, modelo e base.

Decisões a registrar: parâmetros de cada nível por base; resolução em que as degradações foram aplicadas (definida na F4).

F9 — Auditoria de erros (21/11 a 05/12)

A F9 junta o eixo A (associação entre qualidade e FP, FN e calibração) com uma revisão visual codificada dos erros, e fecha com o T3, que só pode rodar depois de F8 e F9.

Passos — eixo A (confirmatório)

- [ ] 9.1 Regressão logística de FN (entre positivos) e de FP (entre negativos) por feature, qualidade em z por fonte, ajuste por posição, idade, sexo e fabricante; erro-padrão agrupado por paciente
- [ ] 9.2 ECE e inclinação de calibração por tercil de qualidade
- [ ] 9.3 Holm nas 4 features primárias; FDR nas secundárias
- [ ] 9.4 Parâmetros físicos do Plus (e do PadChest, se 3.7 confirmar), dentro do fabricante

Passos — revisão qualitativa (exploratória, acréscimo A1)

- [ ] 9.5 Amostra por par modelo × base externa: 25 FP e 25 FN de maior confiança e 25 FP e 25 FN aleatórios (semente 0 do modelo)
- [ ] 9.6 Codificar com um livro de códigos definido na F4: dispositivos e tubos, marcadores e texto, rotação ou corte, inspiração baixa, achado concorrente (derrame, atelectasia), rótulo provavelmente errado, exposição extrema
- [ ] 9.7 Registrar quem codificou; se possível, um radiologista revisa 20% para concordância. Sem segundo avaliador, declarar como limitação

Passo — T3

- [ ] 9.8 Dose-resposta: tendência monotônica em pelo menos 2 dos 3 desfechos no eixo B, controle negativo sem efeito e mesma direção do eixo A

Entregáveis: tabela de razões de chances por 1 DP; curvas de confiabilidade por tercil; tabela de frequência das categorias de erro.

Decisões a registrar: livro de códigos final; amostras sorteadas (IDs com hash).

F10 — Espaço latente e explicabilidade (01/12 a 08/12, cortável)

A F10 é a fase que o protocolo v1.0 não cobre; para não virar desvio, ela entra no texto antes de G4 como exploratória, com FDR e sem nenhuma decisão de modelagem baseada nela. Se o prazo apertar, é a primeira fase a cortar.

Passos

- [ ] 10.1 Extrair os embeddings da penúltima camada (1.024 dimensões após o pooling) para o teste, por modelo e semente
- [ ] 10.2 Sonda de origem: regressão logística linear prevendo a fonte a partir do embedding, validação cruzada por paciente. Comparar com o T2: se o embedding prevê a origem muito melhor que as features de qualidade, o modelo codifica origem além da qualidade medida
- [ ] 10.3 Sonda de qualidade: regressão linear prevendo brilho e contraste a partir do embedding (R^2)
- [ ] 10.4 Projeção 2D (UMAP) colorida por fonte, rótulo e tipo de erro, só descritiva

- [ ] 10.5 Saliência (Grad-CAM) em amostra estratificada de VP, FP e FN: fração da massa de saliência dentro da ROI pulmonar, comparada entre tipos de erro e entre fontes
- [ ] 10.6 Teste de sanidade da saliência por randomização dos pesos (Adebayo et al., 2018): se o mapa não muda, não interpretar

Entregáveis: acurácia das sondas contra T2; figura de projeção; tabela de massa de saliência dentro da ROI.

Decisões a registrar: camada usada; método de saliência; tamanho da amostra.

F11 — Condição estatística (06/12 a 12/12)

A F11 aplica, de uma vez e na ordem pré-registrada, as correções de multiplicidade e as margens, e classifica o resultado em um dos cenários S1 a S5 da §10 sem reinterpretar depois.

Passos

- [ ] 11.1 Reunir todos os p-valores da família primária (lista fechada na F4) e aplicar Holm; secundárias e exploratórias com Benjamini-Hochberg
- [ ] 11.2 Reportar separadamente a incerteza do bootstrap por paciente (2.000) e a dispersão entre as 5 sementes
- [ ] 11.3 Comparações pareadas: bootstrap pareado; DeLong para AUROC
- [ ] 11.4 Aplicar as margens: efeito significativo abaixo da margem é reportado como nulo na prática
- [ ] 11.5 Verificar o poder realizado: largura dos IC por estrato; estratos sem positivos suficientes vão para S5
- [ ] 11.6 Classificar cada par no cenário S1 a S5 pela regra da §10 e registrar a classificação antes de escrever a discussão

Portão G11: todas as análises pré-especificadas executadas, cada uma com IC e classificação registrada.

Decisões a registrar: classificação de cenário por par; análises não executadas e por quê.

F12 e F13 — Reprodutibilidade, redação e entrega (08/12 a 31/12)

A F12 prova que outra pessoa chega aos mesmos números a partir do repositório; a F13 escreve sobre esses números. A data final de entrega ainda precisa ser confirmada.

F12 — Reprodutibilidade

- [ ] 12.1 Ambiente limpo: reinstalar a partir do lock e retreinar um modelo (M1, semente 0); comparar com a tolerância da F5

- [ ] 12.2 Regenerar todas as tabelas e figuras a partir das tabelas de predição com um único comando
- [ ] 12.3 Preencher TRIPOD+AI e CLAIM, o model card e um datasheet por base
- [ ] 12.4 Arquivar código, listas de IDs com hash, features derivadas e tabelas de predição (nunca imagens, §11) com DOI, por exemplo no Zenodo, respeitando os termos de cada base

F13 — Redação e entrega

- [ ] 13.1 Escrever na ordem: métodos (do protocolo v1.1), resultados (das tabelas), limitações (da §11 + desvios), discussão
- [ ] 13.2 Incluir a tabela de desvios completa como apêndice
- [ ] 13.3 Revisão final contra a pergunta da §2.2 e as hipóteses H1 a H4

Acréscimos ao protocolo antes do congelamento

A estratégia do protocolo se mantém; estes dez acréscimos protegem o que já foi planejado e cabem dentro das fases existentes. Os cinco primeiros são os mais importantes, porque depois de G4 só entram como desvio.

ID	Acréscimo	Por que importa	Fase
A1	Revisão qualitativa dos erros com livro de códigos	Seu roteiro tem "auditoria de erros"; o protocolo só tem regressões. Sem pré-especificação, a revisão parece pesca de padrões	F4 → F9
A2	Espaço latente e explicabilidade como exploratórios	Seu roteiro tem esta fase; o protocolo não. A sonda de origem no embedding complementa o T2	F4 → F10
A3	T1 e T2 exploratórios em treino e validação	Mostram atalhos semanas antes de destrancar o teste, sem gastar o teste	F3
A4	Pré-registro com carimbo de tempo (tag + OSF)	Torna verificável que nada foi decidido olhando o teste	F4
A5	Ensaio geral do código na validação e tag antes de G6	Bugs de análise descobertos depois de ver o teste viram tentação de ajuste	F6
A6	Família de testes primários listada nominalmente	H4 não é teste; sem a lista, o Holm fica indefinido	F4

ID	Acréscimo	Por que importa	Fase
A7	Valores faltantes da receita	Razão de subamostragem, "primeira frontal", resolução das degradações e política de incerto estão sem valor	F4
A8	Campos DICOM no CSV do PadChest	Se existirem, melhoram a conversão para 8 bits e ampliam o eixo físico para uma segunda origem	F3
A9	Proveniência dos pixels do RSNA	Se vierem de PNG de 8 bits do NIH, as features do RSNA medem uma imagem já processada; isso muda a redação	F3
A10	Cronograma ajustado	O §12 põe o eixo A até 21/11, mas o teste só abre depois do treino final; o eixo A foi movido para 21/11 a 05/12	F4

Itens que não adicionei de propósito: segunda arquitetura, outras bases e multimodal. Eles ampliariam o escopo que o protocolo já excluiu da v1.

Registro de decisões

Quinze decisões já foram tomadas no planejamento e estão registradas abaixo com a justificativa do protocolo; oito estão propostas ou pendentes e precisam ser fechadas na F4.

ID	Decisão	Alternativas descartadas	Justificativa	Ref.	Estado
D-001	Pneumonia em adultos, radiografias frontais, linguagem de associação	Vários achados; afirmações causais	Pergunta respondível no prazo, com referência por imagem no RSNA	§2.2, §2.5	Tomada
D-002	Modelo fixo: DenseNet121 com pesos ImageNet	Pesos TorchXRayVision; treinar do zero; segunda arquitetura	Padrão da literatura; pesos em NIH ou CheXpert quebrariam a independência; cerca de 6 mil positivos por base	§7.1	Tomada

ID	Decisão	Alternativas descartadas	Justificativa	Ref.	Estado
D-003	Bases: CheXpert Plus, RSNA (Stage 2), PadChest	CheXpert JPG (equalizado); NIH completo (contém o RSNA); MIMIC e VinDr (credenciamento); Kermany e PediCXR (pediatria)	Três origens clínicas distintas: Stanford, NIH, Alicante	§3	Tomada
D-004	Divisão por paciente, 70/10/20, semente 2026, estratificada	Divisão por imagem	Evita vazamento entre partições	§5	Tomada
D-005	Só frontais AP e PA; uma frontal por estudo	Todas as vistas	Não duplicar o rótulo do estudo	§5	Tomada
D-006	PadChest só como teste externo, recorte aleatório de pacientes	Seleção por rótulo; treino com PadChest	Mantém uma origem nunca vista por nenhum modelo	§5	Tomada
D-007	Conversão para 8 bits por regra única por fonte; sem equalização	CLAHE ou normalização por imagem	Equalização apagaria brilho e contraste, que são o objeto de estudo	§6	Tomada
D-008	Sem aumento fotométrico no treino	Aumento de brilho, contraste, ruído	O eixo B perderia sentido se o modelo fosse treinado contra as degradações	§7.2	Tomada
D-009	Subamostrar negativos no treino com correção de prior	Prevalência natural no treino	Viabilidade de treino com 2,7% de positivos	§5, §7.2	Tomada
D-010	Limiar fixado na validação da fonte (sensibilidade 0,90) e reaplicado no externo	Limiar reajustado no externo	Reflete o uso real e expõe a queda externa	§7.2	Proposta
D-011	ECE bruto com 15 bins de igual massa como métrica principal de calibração	Brier como principal	O Brier mistura calibração e discriminação	§9	Tomada
D-012	Nitidez e ruído só dentro de cada base	Comparação entre bases	Resolução, compressão e conversão diferem entre bases	§6	Tomada
D-013	Parâmetros físicos só dentro do fabricante, sem conversão em dose	Converter intensidade em dose	Índices de exposição têm definições diferentes por fabricante	§4.3b	Tomada

ID	Decisão	Alternativas descartadas	Justificativa	Ref.	Estado
D-014	Holm nas primárias, BH nas secundárias, margens 0,02 / 0,02 / 0,03	Sem margem; Bonferroni	Separar significância de relevância prática	§9	Proposta
D-015	Bootstrap por paciente (2.000) e dispersão entre sementes reportados separadamente	Só IC de bootstrap	São fontes de incerteza diferentes	§9	Tomada
D-016	Fração da queda descrita como associada à padronização, não causal	Decomposição causal como principal	Os pesos de importância não identificam causa	§8.5	Tomada
D-017	Multimodal fica para v2; pediatria para v3	Incluir na v1	Prazo e foco	§2.5	Tomada
D-018	Política de rótulo do Plus: positivo = 1; negativo explícito e "não mencionado" = 0; incerto excluído na primária e = 1 na sensibilidade	Incerto = 0; incerto = 1 na primária	A decidir na F4; ver passo 4.2	§4.3c	Pendente
D-019	Espaço latente e explicabilidade como análise exploratória (F10)	Não fazer; fazer sem pré-especificar	Fase do roteiro sem cobertura no protocolo (A2)	novo	Proposta
D-020	Revisão qualitativa dos erros com livro de códigos (F9)	Só regressões	Fase do roteiro sem cobertura no protocolo (A1)	novo	Proposta
D-021	T1 e T2 exploratórios em treino e validação na F3	Só no teste	Diagnóstico precoce sem gastar o teste (A3)	§8.2	Proposta
D-022	Ensaio geral e tag do código de análise antes de destrancar o teste	Escrever a análise depois	Evita ajustes depois de ver o teste (A5)	§5	Proposta
D-023	Pré-registro com tag no git e OSF	Só controle interno	Carimbo de tempo verificável (A4)	§12	Proposta

Modelos de registro: decisão, desvio e diário

Cada decisão nova ganha uma linha na tabela acima e um arquivo curto em `docs/decisoes/`; cada desvio depois de G4 ganha uma linha na tabela abaixo; cada dia de trabalho ganha uma entrada de diário.

Arquivo de decisão (`docs/decisoes/D-0XX.md`)

```
# D-0XX — <título curto>
Data: AAAA-MM-DD · Fase: F? · Estado: Proposta | Tomada
Contexto: o que forçou a decisão (1–3 linhas)
Opções consideradas: A, B, C
Decisão: a opção escolhida, com valores numéricos
Por quê: evidência (ficha, figura, tabela, referência)
Consequência: o que muda no protocolo e nas análises
Reversível até: G4 | G6 | nunca
```

Registro de desvios (só depois de G4)

ID	Data	Seção do protocolo	O que mudou	Motivo	Impacto nos resultados
DV-001					

Entrada de diário (`docs/diario/J-AAAAMMDD.md`)

```
# J-AAAAMMDD
Fase: F? · Passos tocados: 3.2, 3.4
Feito: o que foi executado (comandos, commits)
Observado: números e achados, com denominador
Problemas: o que travou
Decisões ou desvios gerados: D-0XX / DV-0XX
Próximo passo: um item
```