Protocolo científico v1.0 — Qualidade e apresentação de radiografias de tórax, erros, calibração e generalização de classificadores de pneumonia

Autor: [preencher] · Versão 1.0 (rascunho para congelamento) · 17 de outubro de 2026

Modelo fixo: DenseNet121 (pesos ImageNet) · Bases: CheXpert Plus, RSNA Pneumonia (Stage 2) e PadChest

1. Resumo

Este protocolo investiga como a qualidade e a apresentação de radiografias de tórax se relacionam com os erros (falsos positivos e falsos negativos), a calibração e a generalização entre instituições de um classificador de pneumonia. O modelo é mantido fixo (DenseNet121 inicializada em ImageNet) para que as diferenças observadas venham dos dados e não da arquitetura. Três modelos (M1 a M3) são avaliados internamente e em fontes externas. Três eixos de análise (observacional, interventivo e de explicação da queda externa) e três testes de diagnóstico dos dados organizam a investigação. Nada neste documento é resultado: os “resultados esperados” são hipóteses e cenários definidos antes de abrir o conjunto de teste.

2. Problema e pergunta científica

2.1 Contexto e lacuna

- Modelos de pneumonia costumam ter desempenho externo menor que o interno. No estudo de Zech et al. (2018), em 3 de 5 comparações naturais o desempenho em hospitais externos foi significativamente menor [1]. Cohen et al. (2020) apresentam evidência de que o significado dos rótulos muda entre bases, o que é uma explicação alternativa à qualidade da imagem [3]†. Pooch et al. documentam diferenças de intensidade entre bases [2]†.
- Parâmetros de aquisição podem funcionar como atalho: Shu et al. (2026) relatam queda da AUC de pneumotórax de 0,94 para 0,56 quando as distribuições de exposição são invertidas entre treino e teste [4].
- O efeito da qualidade pode ser pequeno: Erenstein et al. (2025) encontraram mudança média de AUROC abaixo de 0,005 sob redução de dose simulada, e o efeito da posição do paciente superou o da dose [5].

- Testes de estresse com gama, contraste, brilho, nitidez e desfoque já existem (CheXpert como desenvolvimento e MIMIC-CXR como externa) [10].
- **Lacuna candidata.** Em busca estruturada de escopo (47 consultas em dois mecanismos de busca; não é revisão sistemática PRISMA) †, não foi identificado estudo que combine simultaneamente: (i) qualidade natural medida; (ii) parâmetros físicos de aquisição; (iii) erros e calibração para pneumonia; (iv) teste em instituição independente; (v) decomposição da fração da queda externa associada à qualidade. Isto é uma lacuna candidata, não prova de ineditismo. A revisão sistemática formal é pendência (seção 12).

2.2 Pergunta principal

> Em fontes clínicas independentes, em que medida diferenças nas distribuições de características naturais de qualidade e de parâmetros de aquisição estão associadas à diferença de erro e de calibração de um classificador de pneumonia, após padronização de fatores clínicos, projeção e referência?

2.3 Hipóteses

- **H1.** Algumas características naturais de qualidade e apresentação estão associadas ao erro (FP e FN), após ajuste predefinido por posição, idade e sexo.
- **H2.** A diferença de desempenho entre fontes diminui após a padronização dessas características.
- **H3.** O efeito sobre as probabilidades (calibração) difere do efeito sobre a discriminação.
- **H4.** O resultado pode ser nulo ou heterogêneo. O protocolo não pressupõe que a qualidade seja a principal explicação.

2.4 Definições operacionais

Termo	Definição operacional
Qualidade natural	Propriedades observadas nos exames como distribuídos, antes de perturbações experimentais, medidas em região pulmonar: brilho, contraste, saturação, enquadramento e, só dentro de cada base, nitidez e ruído. “Natural” não significa sem processamento do fabricante.
Apresentação	Posição (AP/PA), conversão para 8 bits e janelamento aplicados à imagem distribuída.

Termo	Definição operacional
Processamento mínimo	Estado documentado dos pixels e do histórico de processamento (seção 4.3a). Não é presumido.
Parâmetros físicos	Valores registrados no cabeçalho (kVp, corrente, tempo, produto corrente-tempo, índices de exposição), com unidades e validade verificadas.
Erro	FP e FN contra a referência de cada base, com limiar fixo definido na validação da fonte. Não é necessariamente erro clínico verdadeiro.
Calibração	Correspondência entre probabilidades e frequências observadas (ECE, curva de confiabilidade, intercepto e inclinação). Distinta de ajuste de brilho ou escolha de limiar.
Fonte externa independente	Outra origem clínica, sem pacientes ou imagens de teste no desenvolvimento. Outro nome de dataset não basta.
Fração da queda explicada	Redução padronizada do gap externo sob uma padronização explícita (seção 8.5). Não é fração causal.

2.5 Escopo

Dentro: pneumonia em adultos, radiografias frontais, três bases, um modelo fixo, associação e padronização com incerteza.

Fora (versões futuras): v2, aprendizado com laudo + imagem (multimodal); v3, pediatria (PediCXR e Kermany). **Fora definitivo da v1:** segunda arquitetura, afirmações causais, conclusões sobre sinal cru sem prova de processamento mínimo.

3. Bases de dados e papéis

Base	Origem	Papel	Formato e metadados	Referência do rótulo	Observações
CheXpert Plus	Stanford	Treino (M1, M3); teste interno; externa de M2	DICOM com 47 elementos de cabeçalho (exposição, kVp, corrente, fabricante, janela, posição); PNG disponível; demografia	Laudos (CheXpert e CheXbert). Pneumonia: 6.042 positivos, 18.771 incertos, 2.806 negativos, 195.843 “não mencionado” (contagem por imagem)	O melhor rotulador de achados teve F1 de 0,44 contra radiologistas olhando só a imagem, então o rótulo é fraco. Mesmas imagens do CheXpert JPG. Uso só para pesquisa, sem redistribuição.
RSNA Pneumonia (Stage 2)	NIH Clinical Center, rotulado por radiologistas	Treino (M2, M3); teste interno; externa de M1	DICOM, cerca de 26,7 mil imagens; sem laudo em texto; parâmetros físicos provavelmente ausentes (a confirmar)	Radiologistas, por imagem (opacidade pulmonar sugestiva de pneumonia), com caixas	Não é independente do NIH; é independente de Stanford e Alicante. O mapeamento para o NIH fornece o ID de paciente.
PadChest	Hospital Universitário de San Juan, Alicante	Externa (M1, M2, M3)	PNG (sem DICOM), metadados em CSV; laudos em espanhol (não usados na v1)	Laudos: cerca de 27% anotados por médicos e o restante por classificador automático (a confirmar)	Pacote completo de cerca de 1 TB, por solicitação de acesso. Usar recorte aleatório de pacientes.

Excluídas da v1: CheXpert JPG (cópia das mesmas imagens do Plus, gerada com equalização de histograma, o que neutraliza brilho e contraste); NIH completo (contém o RSNA); MIMIC-CXR e VinDr-CXR (credenciamento e prazo); Kermany e PediCXR (v3).

Independência: a v1 usa três origens clínicas distintas: NIH (via RSNA), Stanford e Alicante. CheXpert Plus e CheXpert JPG contam como uma só fonte.

4. Estratégia de auditoria de dados

4.1 Duas portas

- **Porta 1 (viabilidade, até um dia por base):** oito verificações que decidem se a base entra.
- **Porta 2 (ficha completa, 24 perguntas em sete eixos):** proveniência e tamanho; rótulos e anotações; integridade técnica; composição; pixels; dependência; parecer. Só para as três bases escolhidas. Cada resposta registra evidência, escopo, denominador, consequência e pendência, distinguindo o que foi documentado do que foi efetivamente verificado.

4.2 Porta 1: oito verificações

1. Qual é o alvo e quem o rotulou?
2. Existe ID de paciente utilizável?
3. As vistas frontais são filtráveis?
4. Quantos positivos sobram após os filtros?
5. As imagens abrem e correspondem à tabela?
6. Qual é o formato, a profundidade de bits e a resolução?
7. Há sobreposição com outra base?
8. Os termos de uso permitem o uso proposto?

4.3 Auditorias específicas da Porta 2

a) Proveniência do pixel (DICOM). Examinar SOPClassUID, PresentationIntentType, ImageType, PhotometricInterpretation, BitsStored, PixelIntensityRelationship e Sign, LUTs e janelamento, LossyImageCompression e descrições de derivação. A extensão .dcm, a profundidade de bits ou ImageType=ORIGINAL isoladamente não provam dado cru. Sem prova, o texto do trabalho diz “qualidade e apresentação nas imagens distribuídas”.

b) Parâmetros físicos. Verificar presença, unidades, valores plausíveis e distribuição por fabricante e projeção de kVp, corrente, tempo, produto corrente-tempo e índices de exposição. Não converter intensidade em dose. Não comparar índices de exposição entre fabricantes sem verificar a definição. AP/PA é fator de projeção, não medida física.

c) Rótulos. Definir o alvo em cada base e a política de incerteza. Verificar o alinhamento entre alvos: o RSNA mede opacidade pulmonar sugestiva de pneumonia; o Plus, a menção a pneumonia no laudo. Usar a discordância entre os rotuladores CheXpert e CheXbert como indicador de ruído de rótulo.

d) Dependência e sobreposição. Pacientes e estudos, várias imagens por paciente, duplicatas por hash perceptual, mapeamento RSNA para NIH, ausência de sobreposição entre as três origens. O pré-treino em ImageNet não contém radiografias dessas bases.

e) Composição. Posição, idade, sexo, fabricante e prevalência por subgrupo.

f) Pixels. Definição e inspeção da região pulmonar, features de qualidade (seção 6) e conversões aplicadas em cada fonte.

4.4 Critérios de decisão (go/no-go)

- Pelo menos 750 positivos disponíveis para o teste interno de cada base e para cada externa (250 por faixa de qualidade × 3 faixas). Se não houver, usar 2 faixas (500 positivos).
- ID de paciente utilizável. Sem ele, a imagem não entra.
- Região pulmonar segmentável em pelo menos 95% de uma inspeção visual de 100 imagens por base.
- Termos de uso compatíveis com o projeto.
- Se a auditoria do cabeçalho do Plus não encontrar os parâmetros físicos, o eixo A com parâmetros físicos é rebaixado para features de imagem apenas.

5. Divisão dos dados

- **Unidade de divisão:** o paciente. Todas as imagens e estudos de um paciente ficam na mesma partição.
- **Vistas:** apenas frontais (AP e PA) na análise primária. Em estudos com mais de uma frontal, manter a primeira, para não duplicar o rótulo do estudo.
- **CheXpert Plus:** treino 70%, validação 10% e teste 20%, por paciente (semente 2026), estratificado pela presença de ao menos um positivo. No treino, todos os positivos e uma subamostra de negativos, com correção de prior (seção 7). Validação e teste com prevalência natural. Se o tamanho do DICOM exigir, usar subamostra aleatória de pacientes, com mínimo suficiente para 750 positivos de teste (cerca de 28 mil imagens a 2,7% de prevalência).
- **RSNA:** mesma divisão 70/10/20, por paciente NIH (via mapeamento). Imagens sem paciente identificável são excluídas.
- **PadChest:** só teste externo. Recorte aleatório de pacientes, frontais PA/AP, sem seleção por rótulo, com tamanho definido por 750 positivos (prevalência a auditar).
- **M3:** treino pela união dos treinos de Plus e RSNA com amostragem balanceada por fonte; validação por fonte; limiar e temperatura ajustados na validação conjunta; teste externo no PadChest.

- **Congelamento:** listas de ids com hash, versionadas. O conjunto de teste fica trancado até o fim do treino e do protocolo. Nenhuma decisão é tomada olhando o teste.
- **As features de qualidade não participam da divisão.** Os estratos usam percentis de cada partição de teste.

6. Pré-processamento e variáveis de qualidade

Representação de entrada. Uma regra única e documentada por fonte converte cada imagem em 8 bits (cabeçalho DICOM com janela quando existe; caso contrário, escala mínimo-máximo; inversão para MONOCHROME1), redimensionada para 320 × 320. Não há equalização nem normalização adaptativa por imagem, porque elas apagariam o que se quer medir. A conversão do PadChest (PNG de 16 bits) não é a apresentação nativa, então roda-se uma análise de sensibilidade com uma conversão alternativa.

Região de interesse (ROI). Máscara pulmonar por modelo pré-treinado de segmentação (verificar os dados com que ele foi treinado), com ROI central fixa como alternativa. Inspeção visual de 100 imagens por base.

Features de qualidade (calculadas na ROI, antes do redimensionamento):

Feature	Definição	Papel
Brilho	Média das intensidades de 8 bits na ROI	Primária
Contraste	Desvio-padrão na ROI	Primária
Saturação	Fração de pixels da ROI nos extremos (≤1 ou ≥254)	Primária
Enquadramento	Fração de margem preta da imagem	Primária
Amplitude	Faixa p5 a p95 na ROI	Secundária
Entropia	Entropia do histograma na ROI	Secundária
Nitidez	Variância do Laplaciano na ROI, na resolução original	Secundária, só dentro da base
Ruído	Desvio robusto (MAD) de resíduo passa-alta em regiões homogêneas	Secundária, só dentro da base

Parâmetros do cabeçalho (CheXpert Plus): kVp, tempo de exposição, corrente do tubo, produto corrente-tempo, índice de exposição e fabricante. Só comparados dentro do mesmo fabricante, sem conversão para dose.

Nitidez e ruído não são comparáveis entre bases, porque diferem em resolução, compressão e conversão. Entre bases, comparam-se apenas as features marcadas como primárias ou secundárias sem restrição.

7. Modelagem e baselines

7.1 Por que DenseNet121 com pesos ImageNet

- É a arquitetura padrão em radiografia de tórax (por exemplo CheXNet e, segundo a busca estruturada, Pooch et al.), o que favorece a comparabilidade com a literatura.
- Com cerca de 6 mil positivos por base, partir de pesos pré-treinados dá convergência mais estável do que treinar do zero.
- ImageNet não contém radiografias das bases usadas, então o teste externo permanece externo. Pesos treinados em bases como NIH e CheXpert (por exemplo TorchXRayVision) invalidariam a independência.
- Limite: as conclusões valem para uma DenseNet121 inicializada em ImageNet e ajustada nesta receita.

7.2 Receita comum (valores iniciais, a confirmar no congelamento)

Item	Definição
Arquitetura	DenseNet121, pesos ImageNet, canal único replicado em 3 canais
Entrada	320 × 320, 8 bits, média e desvio do ImageNet
Aumento	Apenas geométrico leve (escala 0,9 a 1,0 e rotação de até 5°). **Nenhum aumento fotométrico** (brilho, contraste, gama, desfoque, ruído), para o eixo B ter sentido.
Perda	Entropia cruzada binária. Com subamostragem de negativos, ajuste de prior (logit) e verificação na validação com prevalência natural.
Otimização	AdamW, weight decay 1e-4, lote 32, cosseno, até 30 épocas, early stopping com paciência 5 por AUPRC na validação da fonte
Busca	Taxa de aprendizado em {1e-4, 3e-4}, escolhida só na validação e com a mesma grade para M1 a M3
Sementes	5 (0 a 4)

Item	Definição
Limiar	Fixado na validação da fonte (por exemplo sensibilidade de 0,90) e reaplicado no externo
Calibração	ECE bruto (principal) e ECE após temperatura ajustada na validação da fonte (secundário)

7.3 Modelos

Modelo	Treino	Teste interno	Teste externo
M1	CheXpert Plus	Plus	RSNA, PadChest
M2	RSNA	RSNA	Plus, PadChest
M3	Plus + RSNA (balanceado por fonte)	Plus e RSNA	PadChest

Se o acesso ao PadChest atrasar, M1 e M2 seguem com o cruzamento Plus e RSNA, e o M3 fica sem externo.

7.4 Registro e reprodutibilidade

Versionar código, splits, ambiente e sementes. Cada avaliação grava uma tabela de predições com: id da imagem, id do paciente, id do estudo, fonte, partição, modelo, semente, rótulo, probabilidade, posição, idade, sexo, fabricante e features de qualidade. Todas as análises partem dessa tabela.

8. Experimentos

8.1 E0: desempenho de referência e gap bruto

Para cada par modelo e base: AUROC, AUPRC, FNR, FPR, ECE, intercepto e inclinação de calibração. Gap bruto por métrica. Verificações de sanidade: curvas de treino e validação, nenhum paciente em duas partições, hash perceptual contra duplicatas.

8.2 Testes de diagnóstico dos dados

Teste	Pergunta	Procedimento	Leitura
T1	A qualidade carrega informação do rótulo?	Regressão logística e gradient boosting só com features de qualidade, posição, idade e sexo prevendo pneumonia. Comparar com baseline só de posição. Versão interna e versão treinada numa fonte e testada em outra.	AUROC perto de 0,5: pouca informação. Bem acima: risco de atalho, que pode ser clínico (exame à beira do leito costuma ser AP e de pacientes mais graves).
T2	Existe assinatura de origem?	Classificador de fonte (3 classes) só com features de qualidade comparáveis, também dentro de positivos e de negativos separadamente.	Acerto alto: comparações entre bases misturam origem com qualidade.
T3	O efeito é dose-resposta?	Tendência monotônica no eixo B em pelo menos 2 dos 3 desfechos, controle negativo sem efeito e mesma direção da associação natural do eixo A.	Convergência entre A e B reforça a hipótese. Efeito abaixo da margem conta como nulo.

8.3 Eixo A: observacional

Dentro de cada base, relacionar as features de qualidade com FN (entre positivos), FP (entre negativos) e ECE. Modelo: regressão logística com erro-padrão agrupado por paciente, com qualidade padronizada em z por fonte e ajuste por posição, idade, sexo e fabricante (quando existir). Efeito reportado como razão de chances por 1 DP. ECE e inclinação de calibração por tercil de qualidade. Até 4 features primárias (brilho, contraste, saturação e enquadramento) com correção de Holm; secundárias com FDR. Parâmetros físicos (Plus) analisados dentro do fabricante.

8.4 Eixo B: interventivo

Degradações aplicadas só ao teste, em positivos e negativos igualmente: gama, contraste, brilho, desfoque gaussiano, ruído gaussiano e redução de resolução (reduzir e reampliar). A severidade é ancorada na distribuição natural: níveis que levam a feature

correspondente aos percentis 25, 10 e 5 (e espelhados 75, 90 e 95) da própria base, mais um nível além da faixa. O nível p25/p75 é o controle negativo, no qual se espera efeito pequeno. Medir ΔAUROC, ΔFNR, ΔFPR e ΔECE, com teste de tendência (Mann-Kendall) e tamanho de efeito frente à margem pré-definida (seção 9). Os stress tests existentes [10] servem de âncora.

8.5 Eixo C: explicação da queda externa

Para cada par fonte e externa: `D_bruto = R_interno − R_externo` (sinal orientado para que positivo signifique piora no externo; para ECE e FNR, `R_externo − R_interno`).

- **S1:** padronização do externo para a distribuição clínica da fonte (posição, idade, sexo) por pesos de importância (classificador de domínio por regressão logística, pesos truncados). Gap `D_S1`.
- **S2:** S1 mais as features de qualidade comparáveis entre bases. Gap `D_S2`.
- `Parcela clínica = (D_bruto − D_S1) / D_bruto` e `Parcela de qualidade = (D_S1 − D_S2) / D_bruto`.

Regras: reportar diferenças absolutas antes das razões; se `D_bruto` for próximo de zero, não usar fração; não truncar valores negativos nem acima de 100%; reportar tamanho efetivo da amostra, diferença média padronizada após os pesos (meta < 0,1) e pesos extremos; refazer a estimação dos pesos em cada reamostragem do bootstrap.

Evidências complementares: (i) subconjuntos pareados restritos ao suporte comum de qualidade; (ii) harmonização do externo (mapeamento de quantis do histograma da ROI) em direção à distribuição da fonte e reavaliação; (iii) controles de rótulo: alvo alternativo (“Lung Opacity” do Plus contra o alvo do RSNA), subconjunto com baixa discordância entre rotuladores e, no PadChest, subconjunto rotulado por médicos; (iv) ajuste de prior como sensibilidade, porque ECE e calibração geral dependem da prevalência. A formulação cautelosa é: parcela do gap associada à padronização das características medidas. Decomposição formal (Zhang et al., Kobayashi et al.) fica como análise secundária [7]†.

9. Métricas e análise estatística

Dimensão	Métricas	Observações
Discriminação	AUROC (principal); AUPRC (secundária, com prevalência ao lado)	AUROC não depende da prevalência

Dimensão	Métricas	Observações
Erros	FNR e FPR no limiar fixado na validação da fonte; PPV como complemento	PPV depende da prevalência
Calibração	ECE com 15 bins de igual massa (principal); curva de confiabilidade; intercepto e inclinação; Brier como complemento	O Brier mistura calibração e discriminação. O ECE é enviesado com poucos positivos.
Gap	D_bruto, D_S1, D_S2 e parcelas	Seção 8.5

Incerteza: bootstrap por paciente (2.000 reamostragens) e dispersão entre as 5 sementes, reportadas separadamente. Comparações pareadas por bootstrap pareado (DeLong quando for AUROC).

Multiplicidade: análises primárias predefinidas (H1 a H4, features primárias, tendência do eixo B, parcela de qualidade), $\alpha = 0{,}05$ com Holm; secundárias com FDR de Benjamini-Hochberg.

Margens de relevância (propostas, confirmar no congelamento): ΔAUROC $\geq 0{,}02$; ΔECE $\geq 0{,}02$; ΔFNR ou ΔFPR $\geq 0{,}03$ em valor absoluto. Efeitos abaixo da margem são reportados como nulos para fins práticos, mesmo se estatisticamente significativos.

Relato: checklists TRIPOD+AI e CLAIM, model card e datasheet das bases.

10. Resultados esperados

O que segue são expectativas a priori e regras de leitura, não resultados.

Expectativas conservadoras: (1) queda de desempenho externo e piora de calibração em pelo menos um par, na direção que a literatura sugere; (2) assinatura de origem detectável no T2; (3) associações modestas entre qualidade e erro, mais fortes nos extremos da distribuição; (4) parcela de qualidade positiva, porém minoritária. Um resultado nulo é aceitável e publicável (H4).

Cenário	Evidência	Interpretação
S1. Qualidade explica parte relevante	Parcela de qualidade com IC acima da margem e convergência A ↔ B (T3)	Qualidade medida está associada a parte do gap. Não é prova causal.

Cenário	Evidência	Interpretação
S2. Efeito pequeno ou heterogêneo	Efeitos abaixo da margem; controle negativo e tendência fracos	Coerente com Erenstein et al. [5]. A qualidade medida não é o principal fator.
S3. Atalho dominante	T1 e T2 altos; efeitos grandes no eixo B	Dados não preparados para o modelo: o classificador pode explorar origem ou exposição.
S4. Gap não explicado	Parcela de qualidade perto de zero com gap persistente	Rótulo, população ou prevalência são hipóteses mais fortes (Cohen et al. [3]).
S5. Inconclusivo	IC largos, positivos insuficientes por estrato	Reportar a limitação de poder e as estimativas com IC.

Critério de sucesso do projeto, independente do cenário: todas as análises pré-especificadas executadas, reprodutíveis, reportadas com incerteza e com limitações declaradas.

Entregáveis: fluxograma de dados por base; distribuições das features por base; desempenho interno e externo com IC; curvas de confiabilidade por tercil de qualidade; curvas dose-resposta do eixo B; decomposição do gap (eixo C); tabelas de T1 e T2.

11. Ameaças à validade e limitações

Ameaça	Mitigação
Mudança do significado do rótulo entre bases	Controles de rótulo (seção 8.5); relatar como explicação alternativa
Ruído de rótulo no Plus (F1 de 0,44 contra imagem)	Referência do RSNA por imagem; análise por discordância de rotuladores
Alvos diferentes (opacidade no RSNA, pneumonia no laudo do Plus)	Sensibilidade com “Lung Opacity” do Plus
Confundimento por indicação (AP, leito, gravidade)	Ajuste por posição; baseline T1 só de posição
Processamento dos pixels desconhecido	Auditoria 4.3a; redação “imagens distribuídas”; sensibilidade de conversão
ROI mal segmentada	Inspeção por base; ROI fixa como alternativa

Ameaça	Mitigação
Poucos positivos por estrato	Critério de 750 positivos; reduzir para 2 faixas
Prevalência diferente entre bases	AUROC e inclinação como principais; ajuste de prior como sensibilidade
Independência (RSNA derivado do NIH)	Papel restrito; PadChest como terceira origem
Múltiplas comparações	Holm e FDR; análises primárias predefinidas
Arquitetura e inicialização únicas	Declarar como limitação
Recursos (GPU, disco, Windows)	Cache em 320 px, redução para 224 px ou 3 sementes se necessário
Atraso no acesso ao PadChest	Plano de contingência (seção 7.3)

Conformidade: respeitar os acordos de uso (o Plus é só para pesquisa, sem comercial e sem redistribuição). Armazenar e compartilhar apenas features e tabelas derivadas, nunca as imagens.

12. Cronograma, governança e pendências

Cronograma:

- **Até 31/10:** Portas 1 e 2 (auditoria de cabeçalhos), ROI e features, congelar o protocolo; solicitar o acesso ao PadChest.
- **1 a 21/11:** treinar M1 a M3 (5 sementes), E0, T1 e T2, eixo A.
- **22/11 a 12/12:** eixos B e C, T3.
- **Dezembro:** redação, checklists, limitações e entrega.

Governança: marcos de congelamento (auditoria concluída, protocolo congelado, teste destrancado só após o treino final). Qualquer mudança posterior é registrada como desvio, com data, motivo e impacto.

Pendências abertas:

1. Auditoria dos cabeçalhos do Plus e do RSNA.
2. Tamanho do DICOM do Plus (Redivis) e plano de recorte.
3. Acesso ao PadChest.
4. Modelo de segmentação pulmonar e seus dados de treino.
5. Política de rótulo para incerto e “não mencionado” no Plus.

6. Confirmação das margens de relevância.
7. GPU disponível.
8. Revisão sistemática formal (strings de busca em PubMed, Scopus, Web of Science e Embase).
9. Mapeamento RSNA para NIH e IDs de paciente.

13. Referências

Itens com † vieram do relatório de busca estruturada (v1, 17/10/2026) e precisam de leitura integral confirmada. Os demais tiveram resumo ou texto verificados.

1. Zech JR et al. (2018). Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs. PLOS Medicine. https://pmc.ncbi.nlm.nih.gov/articles/PMC6219764/
2. † Pooch EHP, Ballester PL, Barros RC. Can we trust deep learning models diagnosis? The impact of domain shift in chest radiograph classification. https://arxiv.org/abs/1909.01940
3. † Cohen JP et al. (2020). On the limits of cross-domain generalization in automated X-ray prediction. MIDL/PMLR 121. https://proceedings.mlr.press/v121/cohen20a.html
4. Shu HJ et al. (2026). Impact of exposure parameters on deep learning models in chest radiography and implications for deployment. Radiology: Artificial Intelligence 8(4), e250731. https://doi.org/10.1148/ryai.250731
5. Erenstein H et al. (2025). The effect of simulated dose reduction on the performance of artificial intelligence in chest radiography. Journal of Imaging 11(3), 90. https://doi.org/10.3390/jimaging11030090
6. † Lotter W. (2024). Acquisition parameters influence AI recognition of race in chest x-rays. Nature Communications 15, 7465. https://doi.org/10.1038/s41467-024-52003-3
7. † Zhang H et al. (2023). Why did the model fail? Attributing model performance changes to distribution shifts. ICML/PMLR 202. https://proceedings.mlr.press/v202/zhang23ai.html
8. † Kobayashi Y et al. Underdiagnosis bias of chest radiograph diagnostic AI can be decomposed and mitigated via dataset bias attributions. medRxiv (preprint). https://www.medrxiv.org/content/10.1101/2024.12.16.24319063v2
9. † Samei E et al. (2014). Automated characterization of perceptual quality of clinical chest radiographs. Medical Physics 41(11). https://doi.org/10.1118/1.4899183
10. Robustness stress testing in medical image classification. https://arxiv.org/pdf/2308.06889

11. Chambon P, Delbrouck JB et al. CheXpert Plus: augmenting a large chest X-ray dataset with text radiology reports, patient demographics and additional image formats. https://arxiv.org/pdf/2405.19538
12. RSNA Pneumonia Detection Challenge (2018). https://www.rsna.org/rsnai/ai-image-challenge/rsna-pneumonia-detection-challenge-2018
13. Bustos A et al. (2020). PadChest: a large chest x-ray image dataset with multi-label annotated reports. https://bimcv.cipf.es/bimcv-projects/padchest/
14. † DICOM PS3.3, módulo DX Image, C.8.11.3. https://dicom.nema.org/medical/dicom/current/output/chtml/part03/sect_C.8.11.3.html
15. † Shih G et al. (2019). Augmenting the National Institutes of Health chest radiograph dataset with expert annotations of possible pneumonia. Radiology: Artificial Intelligence. https://doi.org/10.1148/ryai.2019180041