Protocolo científico v1.1

Qualidade e apresentação de radiografias de tórax, erros, calibração e generalização de classificadores de pneumonia

Autora: Aline Lima · Iniciação científica · Versão 1.1 (**congelada** em 30/10/2026) · substitui a v1.0 de 17/10/2026

Modelo fixo: DenseNet121 (pesos ImageNet) · Bases: CheXpert Plus, RSNA Pneumonia (Stage 2) e PadChest

> **Como ler esta versão.** A v1.1 é a v1.0 sem nenhum valor "a confirmar". Ela incorpora o que a auditoria dos dados (fase 3) mediu e as decisões do fechamento (fase 4). A partir do congelamento, qualquer mudança é um **desvio**, registrado com data, motivo e impacto em `docs/desvios/`. As decisões e a evidência de cada uma estão em `docs/decisoes.md`; as mudanças em relação à v1.0 estão resumidas na seção 14.

---

1. Resumo

Este protocolo investiga como a qualidade e a apresentação de radiografias de tórax se relacionam com os erros (falsos positivos e falsos negativos), a calibração e a generalização entre instituições de um classificador de pneumonia. O modelo é mantido fixo (DenseNet121 inicializada em ImageNet), para que as diferenças observadas venham dos dados e não da arquitetura. Três modelos (M1 a M3) são avaliados internamente e em fontes externas. Três eixos de análise (observacional, interventivo e de explicação da queda externa) e três testes de diagnóstico dos dados organizam a investigação, com duas análises exploratórias pré-especificadas (revisão visual dos erros e espaço latente). Nada neste documento é resultado do teste: o conjunto de teste está trancado por hash até 21/11/2026.

2. Problema e pergunta científica

2.1 Contexto e lacuna

- Modelos de pneumonia costumam ter desempenho externo menor que o interno: em 3 de 5 comparações, o desempenho em hospitais externos foi significativamente menor [1].
- O significado dos rótulos muda entre bases, o que é uma explicação alternativa à qualidade da imagem [3]; há diferenças de intensidade entre bases [2].
- Parâmetros de aquisição podem funcionar como atalho: a AUC de pneumotórax caiu de 0,94 para 0,56 quando as distribuições de exposição foram invertidas entre treino e teste [4].
- O efeito da qualidade pode ser pequeno: sob redução de dose simulada, a AUROC mudou menos de 0,005 em média, e a posição do paciente pesou mais que a dose [5].
- Testes de estresse com gama, contraste, brilho, nitidez e desfoque já existem [10].

Lacuna candidata. Numa busca estruturada de escopo (47 consultas; não é revisão sistemática), não apareceu estudo que combine: (i) qualidade natural medida; (ii) parâmetros físicos de aquisição; (iii) erros e calibração para pneumonia; (iv) teste em instituição independente; (v) a parcela da queda externa associada à qualidade. É uma lacuna candidata, não prova de ineditismo; a revisão sistemática formal continua pendente (seção 12).

2.2 Pergunta principal

Em fontes clínicas independentes, em que medida diferenças nas distribuições de características naturais de qualidade e de parâmetros de aquisição estão associadas à diferença de erro e de calibração de um classificador de pneumonia, após padronização de fatores clínicos, projeção e referência?

2.3 Hipóteses

- **H1.** Algumas características naturais de qualidade e apresentação estão associadas ao erro (FP e FN), após ajuste predefinido por posição, idade e sexo (e fabricante, quando existir).
- **H2.** A diferença de desempenho entre fontes diminui após a padronização dessas características, além do que a padronização clínica já reduz.
- **H3.** O efeito sobre as probabilidades (calibração) difere do efeito sobre a discriminação.
- **H4.** O resultado pode ser nulo ou heterogêneo. O protocolo não pressupõe que a qualidade seja a principal explicação. H4 é uma **regra de leitura**, não um teste.

2.4 Definições operacionais

Termo	Definição
Qualidade natural	Propriedades dos exames como distribuídos, antes de qualquer perturbação experimental, medidas na região pulmonar (seção 6). "Natural" não significa sem processamento do fabricante

Apresentação	Posição (AP/PA), conversão para 8 bits e janelamento aplicados à imagem distribuída
Redação	"Qualidade e apresentação nas **imagens distribuídas**", nunca "na aquisição": nenhuma das três bases prova que a imagem não foi processada (auditoria, §4.3a)
Parâmetros físicos	Valores do cabeçalho (kVp, corrente, tempo, produto corrente-tempo, índices de exposição), com unidades e validade verificadas
Erro	FP e FN contra a referência de cada base, com limiar fixado na validação da fonte. Não é necessariamente erro clínico
Calibração	Correspondência entre probabilidades e frequências observadas (ECE, curva de confiabilidade, intercepto e inclinação)
Fonte externa independente	Outra origem clínica, sem pacientes ou imagens de teste no desenvolvimento
Parcela da queda	Redução padronizada do gap externo sob uma padronização explícita (seção 8.5). Não é fração causal

2.5 Escopo

Dentro: pneumonia em adultos (18 a 100 anos), radiografias frontais, três bases, um modelo fixo, associação e padronização com incerteza. Fora (versões futuras): v2, aprendizado com laudo e imagem; v3, pediatria. Fora da v1: segunda arquitetura, afirmações causais, conclusões sobre o sinal cru. O conjunto **CheXthought** (anotações de radiologistas sobre imagens do Plus, divulgado em 28/10/2026) **não faz parte da v1.1**; se for usado depois do acesso, entra como análise adicional, registrada como desvio e rotulada como não pré-registrada.

3. Bases de dados e papéis

Base	Origem	Papel	Pixels	Rótulo (análise principal)
CheXpert Plus	Stanford	Treino de M1 e M3; teste interno; externa de M2	DICOM (Agfa, GE, 14 Varian)	CheXbert da **impressão** do laudo: positivo = 1; negativo explícito e não mencionado = 0; incerto excluído
RSNA Pneumonia (Stage 2)	NIH Clinical Center	Treino de M2 e M3; teste interno; externa de M1	DICOM gerado a partir de PNG de 8 bits do NIH, com compressão JPEG com perda; sem fabricante, janela nem exposição	Grupo final do desafio: positivo = "Lung Opacity"; negativo = "Normal" + "Not Normal"
PadChest	Hospital Universitário de San Juan, Alicante	Só teste externo (M1, M2, M3)	PNG reescalados para 16 bits (Philips, Imaging Dynamics)	Laudos rotulados por médicos (pacotes 0–11 e 54)

Independência. Três origens clínicas distintas (NIH, Stanford, Alicante); nenhum paciente em comum entre elas. O RSNA vem da distribuição oficial da RSNA (não do Kaggle); o paciente é identificado pelos 8 primeiros dígitos do nome original no NIH.

Excluídas da v1: CheXpert JPG (equalizado); NIH completo (contém o RSNA); MIMIC-CXR e VinDr-CXR (credenciamento); Kermany e PediCXR (pediatria).

Termos de uso. O Plus é só para pesquisa, sem uso comercial e sem redistribuição; o PadChest é sempre privado (cláusulas 5 a 7 do acordo). Publicam-se só código, contagens, hashes e resultados agregados; nenhuma imagem, ID ou medida por imagem sai do Redivis.

4. Auditoria dos dados (concluída)

A auditoria seguiu as duas portas da v1.0 (8 verificações de viabilidade e a ficha completa). Os resultados estão em `docs/auditorias/` e `docs/02_auditoria_dos_dados.md`. As três bases foram **aprovadas** pelos critérios da §4.4:

Critério	Plus	RSNA	PadChest
Positivos no teste	690 (≥ 500: **2 faixas** de qualidade)	1.100 (≥ 750: 3 faixas)	796 (≥ 750: 3 faixas)
ID de paciente utilizável	Sim	Sim (via NIH)	Sim
Máscara aceitável (inspeção de 100)	95/100	100/100	97/100
Termos compatíveis	Sim	Sim	Sim

Achados que mudam a análise:

- **Proveniência do pixel (§4.3a).** Nenhuma base prova processamento mínimo; daí a redação "imagens distribuídas".
- **Parâmetros físicos (§4.3b).** No Plus, válidos em cerca de 20% das imagens, quase todas PA da GE; no RSNA, ausentes. O eixo A com parâmetros físicos é **rebaixado a exploratório**, sempre dentro do fabricante.
- **Rótulos (§4.3c).** No Plus, o arquivo do laudo inteiro está desalinhado com as imagens; o rótulo vem da impressão,

com prevalência de cerca de 2,1%. Sensibilidades: incerto = 1; CheXbert dos achados.
- **Confundimento.** No Plus, projeção e fabricante andam juntos (AP é 99,3% Agfa; PA é 87,2% GE). No PadChest, fabricante, saturação e prevalência andam juntos. No RSNA, a prevalência é de 37,9% no AP e 9,2% no PA.
- **Máscara × doença.** Testada em 1.000 imagens do RSNA: a máscara **não depende da doença** pela regra fixada antes; mas o brilho dentro do pulmão é maior nos positivos (seção 8.3, regras de leitura).
- **Duplicatas.** 1 par de pixels idênticos no RSNA e 1 no Plus (mesmo paciente; sai a imagem mais recente); nenhuma duplicata quase idêntica entre pacientes diferentes nas três bases.

5. Divisão dos dados

Regras. Unidade de divisão: o paciente. Só frontais AP e PA; uma frontal por estudo (Plus: menor número de vista; PadChest: PA, depois AP, depois AP deitado; RSNA: já uma por estudo). Adultos de 18 a 100 anos; sexo registrado. Divisão 70/10/20 por paciente, **semente 2026**, estratificada pelo rótulo do paciente (positivo, só incerto, negativo). PadChest inteiro como teste externo. As medidas de qualidade não participam da divisão.

Treino do Plus. Todos os positivos do treino e **4 negativos por positivo**, sorteados **uma vez** (semente 2026); as 5 sementes de treino usam o mesmo conjunto e variam só a inicialização e a ordem dos lotes. Incertos fora do treino. Validação e teste com prevalência natural.

RSNA. Conjunto de treino do desafio (Stage 2) na análise principal; as 3.000 imagens do teste do Kaggle (enriquecido, outro processo de rotulagem) só como sensibilidade.

M3. União dos treinos de Plus e RSNA com amostragem balanceada por fonte; validação por fonte; limiar e temperatura na validação conjunta; teste externo no PadChest.

Listas geradas (28 a 30/10/2026), `src/divisao/listas.py`. O SHA-256 é calculado sobre os IDs ordenados, um por linha; os IDs ficam só no Redivis.

Base	Partição	Imagens	Pacientes	Positivos	SHA-256 (início)
Plus	Treino	123.055	43.982	2.420	`8886d430…`
Plus	Treino sorteado (usado pelo modelo)	12.100	9.320	2.420	`7f554299…`
Plus	Validação	18.147	6.284	334	`6e36fdc8…`
Plus	**Teste**	35.457	12.566	690	`7437a920…`
RSNA	Treino	17.948	7.647	4.047	`da15b3d1…`
RSNA	Validação	2.417	1.092	480	`eb13f9a0…`
RSNA	**Teste**	5.037	2.185	1.100	`c4de2e1c…`
PadChest	**Teste externo**	24.770	22.985	796	`0786ca66…`

Os hashes completos estão em `data/splits/listas_sha256.json`. As listas de teste ficam numa pasta separada (`listas_teste_trancado/`) que nenhum código de treino lê (verificado por busca no repositório). **Nenhuma decisão é tomada olhando o teste.**

6. Pré-processamento e variáveis de qualidade

Conversão para 8 bits (regra única nas três bases): mínimo-máximo pelos percentis 0,5 e 99,5 da própria imagem, com inversão de MONOCHROME1; sem equalização nem normalização adaptativa. Redimensionamento direto para 320 × 320 (área). **Sensibilidade com a janela:** no PadChest, a janela do CSV reescalada, só no Philips (no Imaging Dynamics a janela corta as pontas e não serve como verificação); no Plus, a janela do DICOM como análise **exploratória descritiva** (concordância de brilho com os percentis de −0,04: a janela reordena as imagens sem cortá-las).

Região de interesse. Máscara pulmonar do `lungs-segmentation` (resnet34, treinado só em Montgomery e Shenzhen; nenhuma das três bases), mesmo procedimento nas três bases; máscara central fixa como sensibilidade.

Medidas (`src/qualidade/medidas.py`), na resolução original, sobre a imagem já convertida para 8 bits, dentro da máscara:

Medida	Definição	Papel
Brilho	Média dos tons de 8 bits	Primária
Contraste	Desvio-padrão	Primária
Saturação	Fração dos pixels ≤ 1 ou ≥ 254	Primária
Enquadramento	Fração da imagem em regiões pretas (≤ 5) ligadas à borda	Primária
Amplitude	p95 − p5	Secundária
Entropia	Entropia (bits) do histograma de 256 tons	Secundária

Nitidez	Variância do Laplaciano 3 × 3	Secundária, só dentro da base
Ruído	1,4826 × MAD do resíduo (imagem − gaussiana σ = 1,5) nos 20% de pixels mais homogêneos	Secundária, só dentro da base

Medidas auxiliares (área da máscara, saturação nativa) são só descritivas. As medidas já foram calculadas nas três bases: PadChest 24.773 imagens, RSNA 25.408, Plus 65.705 (as que o estudo usa).

Parâmetros físicos: só exploratórios, só dentro do fabricante, sem conversão em dose (Plus: GE; RSNA: ausentes; PadChest: campos do CSV dentro de Philips e Imaging Dynamics).

7. Modelagem

7.1 Por que DenseNet121 com pesos ImageNet

Arquitetura padrão em radiografia de tórax, o que favorece a comparação com a literatura; com poucos milhares de positivos por base, partir de pesos pré-treinados converge melhor que treinar do zero. O ImageNet não contém radiografias das bases usadas; pesos treinados em NIH ou CheXpert quebrariam a independência. As conclusões valem para esta arquitetura, inicialização e receita.

7.2 Receita (`configs/base.yaml`)

Item	Valor
Entrada	320 × 320, 8 bits, canal único replicado em 3, normalização do ImageNet
Aumento	Só geométrico: escala de 0,9 a 1,0 e rotação de até 5°. Nenhum aumento fotométrico
Perda	Entropia cruzada binária, com correção de prior pela subamostragem: logit corrigido = logit + ln(π_nat / (1 − π_nat)) − ln(π_treino / (1 − π_treino)), verificada na validação com prevalência natural
Otimização	AdamW, weight decay 1e-4, lote 32, cosseno, até 30 épocas, parada antecipada com paciência 5 pela AUPRC na validação da fonte
Busca	Taxa de aprendizado em {1e-4, 3e-4}, só na validação, mesma grade para M1 a M3
Sementes	5 (0 a 4)
Limiar	Sensibilidade de 0,90 na validação da fonte, reaplicado no externo (M3: validação conjunta)
Calibração	ECE bruto (principal) e ECE após temperatura ajustada na validação da fonte (secundário)
Recursos	GPU NVIDIA L4 no Redivis (cerca de 34 vezes mais rápida que a CPU no teste da fase 2); 21 treinos estimados em 10 a 20 h. Contingência (§11): 224 px ou 3 sementes, registrada como desvio

7.3 Modelos

Modelo	Treino	Teste interno	Teste externo
M1	Plus	Plus	RSNA, PadChest
M2	RSNA	RSNA	Plus, PadChest
M3	Plus + RSNA (balanceado por fonte)	Plus e RSNA	PadChest

São 9 pares modelo-base e 5 pares externos.

7.4 Registro e reprodutibilidade

Código, listas (por hash), ambiente e sementes versionados. Cada avaliação grava uma tabela de predições validada por `configs/schema_predicoes.yaml`: imagem, paciente, estudo, fonte, partição, modelo, semente, rótulo, probabilidade, posição, idade, sexo, fabricante, medidas de qualidade, degradação e nível. Todas as análises partem dessa tabela.

Ensaio geral e trava do teste. Antes de abrir o teste, todas as análises (E0, eixos A, B e C, T1 a T3) rodam sobre as partições de validação, para depurar o código; o código de análise é congelado com uma tag no git; só então o teste é destrancado (21/11/2026), com data, hora, hashes e tag registrados no diário.

8. Experimentos

8.1 E0: desempenho de referência e gap bruto

Para cada par modelo-base: AUROC, AUPRC (com a prevalência ao lado), FNR, FPR, ECE, intercepto e inclinação de calibração. Gap bruto por métrica. Sanidade: nenhum paciente em duas partições; treino com rótulos embaralhados deve dar AUROC perto de 0,5; sobreajuste proposital de um lote pequeno deve levar a perda a perto de zero.

8.2 Testes de diagnóstico dos dados

Teste	Pergunta	Procedimento	Leitura
T1	A qualidade carrega informação do rótulo?	Regressão logística e gradient boosting só com medidas de qualidade, posição, idade e sexo prevendo pneumonia, contra uma linha de base só com a posição; versão interna e cruzada. **Reportado com e sem o brilho** (seção 8.3)	AUROC perto de 0,5: pouca informação. Bem acima: risco de atalho, que pode ser clínico
T2	Existe assinatura de origem?	Classificador de fonte (3 classes) só com medidas comparáveis entre bases, também dentro de positivos e de negativos	Acerto alto: comparar bases mistura origem com qualidade
T3	O efeito tem dose-resposta?	Tendência monotônica no eixo B em pelo menos 2 dos 3 desfechos, controle negativo (p25/p75) sem efeito e mesma direção do eixo A	Convergência de A e B reforça H1; efeito abaixo da margem conta como nulo

T1 e T2 rodam antes, em treino e validação, como **diagnóstico exploratório** (sem gastar o teste), e depois no teste, como análise confirmatória, com AUROC e intervalo de confiança, sem p-valor de hipótese.

8.3 Eixo A: observacional

Dentro de cada base, as medidas de qualidade são relacionadas a FN (entre positivos), FP (entre negativos) e ECE. Regressão logística com a qualidade padronizada em z por fonte, ajuste por posição, idade, sexo e fabricante (quando existir), e erro-padrão agrupado por paciente; efeito em razão de chances por 1 desvio-padrão. **As 5 sementes entram juntas na mesma regressão** (um p-valor por teste). ECE e inclinação de calibração por faixa de qualidade (Plus: 2 faixas; RSNA e PadChest: 3).

Brilho e opacidade (regras fixadas antes do teste). O brilho dentro do pulmão é maior nos positivos (diferença padronizada de 0,39 no AP e 0,16 no PA, no teste da máscara): parte do "brilho" é a própria opacidade. Por isso: (1) o brilho é lido principalmente no modelo de **falsos positivos** (entre negativos); no de falsos negativos, é reportado com a ressalva de que pode refletir a extensão da opacidade; (2) o T1 é reportado com e sem o brilho; (3) no eixo C, os pesos de S2 são estimados **dentro de cada classe**; (4) o eixo B é a verificação do efeito do brilho sem a doença no meio.

8.4 Eixo B: interventivo

Onde cada degradação é aplicada. Gama, contraste e brilho mudam cada pixel e quase não dependem da resolução: são aplicados na **imagem de 320 px**. Desfoque gaussiano, ruído gaussiano e redução de resolução (reduzir e reampliar) mudam a relação entre vizinhos: são aplicados na **resolução original**, depois da conversão para 8 bits e antes da redução para 320 px (`src/perturbations/degradacoes.py`).

Níveis. Cada degradação leva a sua medida aos percentis p25, p10, p5 e p1 (ou p75, p90, p95 e p99) do teste natural da própria base, na resolução em que é aplicada, para o lado em que age (desfoque e resolução: nitidez para baixo; ruído: para cima; gama e brilho: os dois lados; contraste: para baixo). O nível p25/p75 é o **controle negativo**. O **nível além da faixa** das degradações espaciais é o parâmetro que leva a medida, **medida em 320 px**, ao p5 (nitidez) ou p95 (ruído) natural em 320 px: um **controle positivo** de que a degradação chega ao modelo. Cada curva espacial reporta o efeito no original e em 320 px. O erro de ancoragem (medida após a degradação × percentil-alvo) é registrado. Os parâmetros finais de cada nível por base são fixados na fase 8, com a grade ampliada, antes de qualquer predição.

Piloto (30/10/2026, 50 imagens da validação do Plus e do RSNA). Brilho e contraste em 320 px concordam com o original (concordância de postos de 0,997 a 1,000). Nos níveis naturais, as degradações espaciais quase não chegam a 320 px (ruído: 0,01 a 0,1 desvio-padrão; desfoque: 0,1 a 0,35 no RSNA e menos no Plus), porque a redução para 320 px é de cerca de 6 vezes no Plus e 3 no RSNA. Daí o controle positivo.

Amostra. Todos os positivos do teste e 4 negativos por positivo, sorteados por paciente (semente 2026), a mesma para as 6 degradações e os 15 modelos (Plus: 3.450 imagens; RSNA: 5.037, o teste inteiro; PadChest: 3.980). AUROC, FNR e FPR não dependem da proporção de negativos; o ECE é calculado com pesos que devolvem a prevalência natural.

Desfechos. ΔAUROC, ΔFNR, ΔFPR e ΔECE em relação à imagem natural. **Teste de tendência** com todas as imagens: FNR e FPR por regressão logística do erro de cada imagem sobre o nível (0, 1, 2…), com erro-padrão agrupado por paciente; AUROC pela inclinação do ΔAUROC entre níveis, com bootstrap pareado por paciente. O Mann-Kendall sobre os pontos da curva é só descritivo (com 5 a 6 pontos, o menor p possível é cerca de 0,003).

8.5 Eixo C: explicação da queda externa

Para cada par fonte-externa: D_bruto = R_interno − R_externo, orientado para que positivo signifique piora no externo (para ECE e FNR, R_externo − R_interno).

- **S1:** padronização do externo para a distribuição clínica da fonte (posição, idade, sexo) por pesos de importância (classificador de domínio por regressão logística, pesos truncados). Gap D_S1.
- **S2:** S1 mais as medidas de qualidade comparáveis entre bases, com os pesos estimados **dentro de cada classe** (positivos e negativos separados). Gap D_S2.
- Parcela clínica = (D_bruto − D_S1) / D_bruto; parcela de qualidade = (D_S1 − D_S2) / D_bruto.

Regras: diferenças absolutas antes das razões; sem fração se D_bruto for próximo de zero; sem truncar valores negativos ou acima de 100%; reportar tamanho efetivo da amostra, diferença média padronizada após os pesos (meta < 0,1) e pesos extremos; reestimar os pesos em cada reamostragem do bootstrap.

Evidências complementares: suporte comum de qualidade; harmonização do externo por mapeamento de quantis do histograma da máscara; controles de rótulo ("Lung Opacity" do Plus contra o alvo do RSNA; subconjunto com baixa discordância entre rotuladores no Plus; subconjunto médico do PadChest, que é o recorte inteiro); ajuste de prior como sensibilidade. Formulação: "parcela do gap associada à padronização das características medidas". Decomposições formais [7, 8] ficam como análise secundária.

8.6 Análises exploratórias pré-especificadas

Exploratórias: com Benjamini-Hochberg quando houver p-valor, sem nenhuma decisão de modelagem baseada nelas.

Revisão visual dos erros (fase 9). Por par modelo × base externa: 25 FP e 25 FN de maior confiança e 25 FP e 25 FN sorteados (semente 0 do modelo), com IDs registrados por hash. Livro de códigos: dispositivos e tubos; marcadores e texto gravado na imagem (por exemplo "PORTABLE"); rotação ou corte; inspiração baixa; achado concorrente (derrame, atelectasia); rótulo provavelmente errado; exposição extrema. Codificação pela autora; se possível, um radiologista revisa 20% para concordância. Sem segundo avaliador, isso é declarado como limitação.

Espaço latente e explicabilidade (fase 10, a primeira a ser cortada se faltar prazo). Embeddings da penúltima camada (1.024 dimensões após o pooling) no teste, por modelo e semente. Sonda de origem: regressão logística linear prevendo a fonte a partir do embedding, com validação cruzada por paciente, comparada ao T2. Sonda de qualidade: regressão linear prevendo brilho e contraste (R^2). Projeção 2D (UMAP) só descritiva. Saliência (Grad-CAM) numa amostra estratificada de VP, FP e FN: fração da saliência dentro da máscara pulmonar, entre tipos de erro e entre fontes, com teste de sanidade por randomização dos pesos [16]; se o mapa não muda, não é interpretado.

Outras exploratórias: janela do DICOM no Plus; parâmetros físicos dentro do fabricante; brilho no modelo de FN.

9. Métricas e análise estatística

Dimensão	Métricas	Observação
Discriminação	AUROC (principal); AUPRC (secundária, com a prevalência ao lado)	A AUROC não depende da prevalência
Erros	FNR e FPR no limiar fixado; PPV como complemento	O PPV depende da prevalência
Calibração	ECE com 15 faixas de igual tamanho (principal); curva de confiabilidade; intercepto e inclinação; Brier como complemento	O ECE é enviesado com poucos positivos
Gap	D_bruto, D_S1, D_S2 e parcelas	Seção 8.5

Incerteza. Bootstrap por paciente (2.000 reamostragens) e dispersão entre as 5 sementes, reportados separadamente. Comparações pareadas por bootstrap pareado (DeLong para AUROC).

Margens de relevância. AUROC: 0,02. FNR e FPR: 0,03. ECE: o menor entre 0,02 e um quarto da prevalência da base (Plus cerca de 0,005; PadChest cerca de 0,008; RSNA 0,02), porque com prevalência de 2 a 3% o ECE fica perto de 0,01 e uma margem absoluta nunca seria alcançada. Precisão esperada (IC 95% de um AUROC isolado): ± 0,015 a 0,021.

Leitura de cada comparação: relevante se o intervalo de confiança inteiro fica acima da margem; **nulo na prática** se fica inteiro abaixo; **inconclusivo** se cruza a margem (alimenta o cenário S5).

Multiplicidade: três famílias primárias, com Holm (α = 0,05) dentro de cada uma.

Família	Hipótese	Testes	Quantos
1. Eixo A	H1	Brilho, contraste, saturação e enquadramento × FN e FP × 9 pares modelo-base	72
2. Eixo B	Resposta à piora da imagem	Tendência do ΔAUROC em gama, brilho e contraste × 9 pares	27
3. Eixo C	H2	Parcela de qualidade no AUROC nos 5 pares externos (M1 → RSNA e PadChest; M2 → Plus e PadChest; M3 → PadChest)	5

Cada família corresponde a uma hipótese pré-registrada; uma família única de 104 testes tornaria impossível rejeitar os testes por bootstrap (com 2.000 reamostragens, o menor p é 0,0005). **Benjamini-Hochberg (secundárias):** medidas secundárias; degradações espaciais; FNR, FPR e ECE no eixo B; calibração por faixa; parâmetros físicos; parcela de qualidade nas outras métricas. **H3** é lida pelo padrão (os eixos B e C mexem mais no ECE que na AUROC?), sem teste próprio; **H4** é regra de leitura; **T1 e T2** são reportados com AUROC e intervalo, sem p-valor.

Relato: TRIPOD+AI, CLAIM, model card e um datasheet por base.

10. Resultados esperados e cenários

Expectativas a priori, não resultados: (1) queda externa e piora de calibração em pelo menos um par; (2) assinatura de origem detectável no T2; (3) associações modestas entre qualidade e erro, mais fortes nos extremos; (4) parcela de qualidade positiva, porém minoritária; (5) pelo piloto, curvas espaciais quase planas nos níveis naturais, com resposta só no controle positivo. Um resultado nulo é aceitável e publicável (H4).

Cenário	Evidência	Interpretação
S1. Qualidade explica parte relevante	Parcela de qualidade com IC acima da margem e convergência A ↔ B (T3)	Qualidade medida associada a parte do gap. Não é prova causal
S2. Efeito pequeno ou heterogêneo	Efeitos abaixo da margem; controle negativo e tendência fracos	Coerente com [5]: a qualidade medida não é o principal fator
S3. Atalho dominante	T1 e T2 altos; efeitos grandes no eixo B	O classificador pode explorar origem ou exposição
S4. Gap não explicado	Parcela de qualidade perto de zero com gap persistente	Rótulo, população ou prevalência são hipóteses mais fortes [3]
S5. Inconclusivo	Intervalos que cruzam a margem; positivos insuficientes por estrato	Reportar a limitação de poder e as estimativas com IC

Cada par é classificado num cenário **antes** de escrever a discussão. Critério de sucesso, em qualquer cenário: todas as análises pré-especificadas executadas, reprodutíveis, com incerteza e limitações declaradas.

11. Ameaças à validade e limitações

Ameaça	Mitigação
Significado do rótulo muda entre bases; alvos diferentes (opacidade no RSNA, menção no laudo do Plus)	Controles de rótulo (§8.5); relatar como explicação alternativa
Ruído de rótulo no Plus	Referência por imagem no RSNA; subconjunto de baixa discordância entre rotuladores; sensibilidade incerto = 1
Brilho no pulmão mistura apresentação e opacidade	Regras de leitura da §8.3; eixo B como verificação
Confundimento por projeção, fabricante e gravidade	Ajuste por posição; T1 contra linha de base só de posição; análises dentro do fabricante
Processamento dos pixels desconhecido; RSNA já convertido para 8 bits e comprimido	Redação "imagens distribuídas"; sensibilidade de conversão
Degradações espaciais quase apagadas pela redução para 320 px	Controle positivo e efeito em 320 px reportados (§8.4); conclusão restrita a esta resolução de entrada
Máscara mal segmentada	Inspeção por base; teste de dependência da doença; máscara central como sensibilidade
Poucos positivos no Plus (690)	2 faixas de qualidade; leitura em três saídas com a margem
Prevalência diferente entre bases	AUROC e inclinação como principais; margem do ECE escalada; ajuste de prior como sensibilidade
Independência (RSNA derivado do NIH)	Papel restrito; PadChest como terceira origem
Múltiplas comparações	Três famílias com Holm; Benjamini-Hochberg nas secundárias
Arquitetura e inicialização únicas	Declarado como limitação
Recursos (GPU, cota de 10 GB no Redivis)	Créditos reservados à GPU; derivados no `/out`; contingência de 224 px ou 3 sementes
Uma só codificadora na revisão dos erros	Revisão de 20% por radiologista, se possível; senão, limitação declarada

12. Cronograma, governança e pendências

Fase	Período
Congelamento do protocolo (este documento)	30/10
F5 — Linha de base (M1 piloto, sanidade, determinismo)	1 a 7/11
F6 — M1 a M3 × 5 sementes, limiar, temperatura, ensaio geral	8 a 20/11
Geração das imagens degradadas da amostra (CPU, em paralelo ao treino)	1 a 20/11
Destrancamento do teste	**21/11**
F7 — Generalização (E0, T1, T2, eixo C)	21/11 a 4/12

F8 — Eixo B	24/11 a 5/12
F9 — Eixo A, revisão dos erros, T3	21/11 a 5/12
F10 — Espaço latente (cortável)	1 a 8/12
F11 — Estatística e cenários	6 a 12/12
F12 — Reprodutibilidade	8 a 15/12
F13 — Redação e entrega	13 a 31/12 (data final a confirmar)

Governança. Marcos: auditoria concluída (30/10), protocolo congelado (30/10), teste destrancado só após o treino final e o congelamento do código de análise (21/11). Depois do congelamento, toda mudança é desvio (`docs/desvios/`), com data, motivo e impacto.

Pendências que não mudam o que está congelado: revisão sistemática formal (strings em PubMed, Scopus, Web of Science e Embase); T1 e T2 exploratórios em treino e validação; rótulos do rotulador CheXpert no Plus (para o controle de discordância); descrição de raça e etnia no Plus; acesso ao CheXthought (fora da v1.1).

13. Referências

1. Zech JR et al. (2018). Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs. *PLOS Medicine*. https://pmc.ncbi.nlm.nih.gov/articles/PMC6219764/
2. Pooch EHP, Ballester PL, Barros RC. Can we trust deep learning models diagnosis? The impact of domain shift in chest radiograph classification. https://arxiv.org/abs/1909.01940
3. Cohen JP et al. (2020). On the limits of cross-domain generalization in automated X-ray prediction. *MIDL/PMLR* 121. https://proceedings.mlr.press/v121/cohen20a.html
4. Shu HJ et al. (2026). Impact of exposure parameters on deep learning models in chest radiography and implications for deployment. *Radiology: Artificial Intelligence* 8(4), e250731. https://doi.org/10.1148/ryai.250731
5. Erenstein H et al. (2025). The effect of simulated dose reduction on the performance of artificial intelligence in chest radiography. *Journal of Imaging* 11(3), 90. https://doi.org/10.3390/jimaging11030090
6. Lotter W. (2024). Acquisition parameters influence AI recognition of race in chest x-rays. *Nature Communications* 15, 7465. https://doi.org/10.1038/s41467-024-52003-3
7. Zhang H et al. (2023). Why did the model fail? Attributing model performance changes to distribution shifts. *ICML/PMLR* 202. https://proceedings.mlr.press/v202/zhang23ai.html
8. Kobayashi Y et al. Underdiagnosis bias of chest radiograph diagnostic AI can be decomposed and mitigated via dataset bias attributions. *medRxiv*. https://www.medrxiv.org/content/10.1101/2024.12.16.24319063v2
9. Samei E et al. (2014). Automated characterization of perceptual quality of clinical chest radiographs. *Medical Physics* 41(11). https://doi.org/10.1118/1.4899183
10. Robustness stress testing in medical image classification. https://arxiv.org/pdf/2308.06889
11. Chambon P, Delbrouck JB et al. CheXpert Plus: augmenting a large chest X-ray dataset with text radiology reports, patient demographics and additional image formats. https://arxiv.org/pdf/2405.19538
12. RSNA Pneumonia Detection Challenge (2018). https://www.rsna.org/rsnai/ai-image-challenge/rsna-pneumonia-detection-challenge-2018
13. Bustos A et al. (2020). PadChest: a large chest x-ray image dataset with multi-label annotated reports. https://bimcv.cipf.es/bimcv-projects/padchest/
14. DICOM PS3.3, módulo DX Image, C.8.11.3. https://dicom.nema.org/medical/dicom/current/output/chtml/part03/sect_C.8.11.3.html
15. Shih G et al. (2019). Augmenting the National Institutes of Health chest radiograph dataset with expert annotations of possible pneumonia. *Radiology: Artificial Intelligence*. https://doi.org/10.1148/ryai.2019180041
16. Adebayo J et al. (2018). Sanity checks for saliency maps. *NeurIPS*. https://arxiv.org/abs/1810.03292

14. Mudanças da v1.0 para a v1.1

Seção	v1.0	v1.1	Origem
§2.4, §11	"Processamento mínimo" a verificar	Redação "imagens distribuídas"	Auditoria (F3 › Todas › Redação)
§2.5	—	CheXthought fora da v1.1	F4 › Plus › CheXthought
§3	Rótulo do Plus por laudo; prevalência 2,7%; PadChest em recorte aleatório	Rótulo da impressão (≈ 2,1%), incerto excluído; PadChest = pacotes 0–11 e 54, rotulados por médicos; RSNA da distribuição oficial	Auditorias finais
§4	Critérios a aplicar	Três bases aprovadas; Plus com 2 faixas	Auditorias finais
§5	Razão de negativos, "primeira frontal" e recorte a definir	4 negativos por positivo, sorteados uma vez; regra de primeira frontal por base; listas com SHA-256	F4 › Todas › Receita; F4 › Todas › Listas
§6	Conversão "janela quando existe, senão mínimo-máximo"	Percentis 0,5–99,5 em todas; janelas só como sensibilidade ou exploratória; definições exatas das 8 medidas; máscara `lungs-`	F3 › Todas › Conversão, Medidas, Máscara

		`segmentation`	
§6, §8.3	Eixo A com parâmetros físicos	Parâmetros físicos só exploratórios, dentro do fabricante	F3 › Plus › Física
§8.2, §8.3, §8.5	—	Regras de leitura do brilho (FP como leitura principal; T1 com e sem brilho; pesos de S2 dentro da classe)	F4 › Todas › Brilho e opacidade
§8.4	Resolução das degradações não definida; Mann-Kendall como teste	Fotométricas em 320 px, espaciais no original; controle positivo; amostra fixa; teste de tendência com todas as imagens	F4 › Todas › Degradações do eixo B; F4 › Todas › Testes primários
§8.6	—	Revisão visual dos erros e espaço latente como exploratórias	Plano › Todas › Revisão dos erros; Espaço latente
§7.4	—	Ensaio geral na validação e tag do código antes de abrir o teste	Plano › Todas › Ensaio geral
§9	Margens propostas; família primária vaga	Margens confirmadas, ECE escalado pela prevalência; regra das três saídas; três famílias nominais (72, 27 e 5); sementes juntas na regressão	Plano › Todas › Estatística; F4 › Todas › Testes primários
§12	Eixo A até 21/11	Cronograma do plano de execução; pendências que não mudam o congelado	Plano de execução

Pré-registro. O SHA-256 deste PDF é registrado em `docs/protocolo/protocolo_v1.1.pdf.sha256`, no registro do congelamento (`docs/trajetoria.md`, seção 8) e numa tag no git (`protocolo-v1.1`); se possível, também no OSF.